

Türkiye'de Gram Altın Fiyatlarının Makine Öğrenmesi Tabanlı Tahmini

Literatür taraması raporu: 23 çalışmanın karşılaştırmalı analizi ve önerilen yöntem

10 Ekim 2026

1. Giriş ve Kapsam

İncelenen 23 çalışmanın hiçbirisi, Türkiye'de gram altının TL/gram cinsinden ertesi gün fiyatını, kronolojik doğrulama ve basit referans modeliyle karşılaştırarak tahmin etmemektedir. Bu proje tam olarak bu boşluğu hedeflemektedir.

Projenin amacı, geçmiş gram altın fiyatları, ons altın, USD/TRY kuru ve ilişkili göstergelerle kısa vadeli (T+1) fiyat tahmini yapmaktır. Farklı makine öğrenmesi modelleri karşılaştırılacak ve sonuçlar bir web uygulamasıyla sunulacaktır.

Tarama 2011–2026 arasında yayımlanmış Türkçe ve uluslararası çalışmaları kapsar. Çalışmalar beş temaya ayrılmıştır; bir çalışma birden fazla temada yer alabilir.

Tema	Çalışmalar	Projeye katkısı
Fiyatı belirleyen faktörler (ekonometrik)	Yurdakul ve Sefa (2015); Toraman vd. (2011); Türkiye uzun hafıza çalışması (2014)	Değişken seçimi ve piyasa davranışı
Tekil makine öğrenmesi karşılaştırmaları	Das vd. (2022); Manjula ve Karthikeyan (2019); Makala ve Li (2021); Abar (2020); Öndes ve Oğuzlar (2019); Sürücü ve Türkan (2026); Akkuş (2025); Duman vd. (2025); İkasatya vd. (2026)	Model adaylarının belirlenmesi
Fiziksel / gram altın ve günlük tahmin	Kocatepe ve Yıldız (2016); Hisyam vd. (2025); Akbar (2026); Ashari vd. (2026); Aladağ vd. (2012)	Hedef değişkene en yakın örnekler
Hibrit ve tahmin birleştirme	Shang ve Hamori (2023); Ashari vd. (2026); Nainggolan vd. (2026); ICITISEE (2025); Çınarer (2025); Aladağ vd. (2012)	Hibrit model tasarımı
Değerlendirme metodolojisi	Bergmeir vd. (2018); Dael (2026)	Doğrulama ve test tasarımı

2. Altın Fiyatını Belirleyen Faktörler

Literatürde en tutarlı belirleyiciler uluslararası altın fiyatı ve dolar göstergeleridir. Gümüş ve ABD faiz göstergeleri makine öğrenmesi çalışmalarında sık öne çıkar; petrol ve enflasyonun etkisi ise çalışmadan çalışmaya değişir.

Ekonometrik çalışmalar. Yurdakul ve Sefa (2015), 1996–2012 aylık verilerle İstanbul Altın Borsası fiyatını incelemiş ve EGARCH(1,1) modelini en uygun model bulmuştur. Uluslararası altın fiyatı ve Toptan Eşya Fiyat Endeksi pozitif, Dow Jones endeksi negatif ilişkili çıkmıştır.

Toraman vd. (2011), 1992–2010 aylık verilerle MGARCH-CCC modeli kurmuştur. Altın ile dolar endeksi arasında yaklaşık $-0,476$ koşullu korelasyon bulunmuş; petrol, enflasyon, Dow Jones ve reel faiz anlamlı çıkmamıştır. Yazarlar ilişkilerin doğrusal olmayabileceğini vurgulamıştır.

Türkiye uzun hafıza çalışması (2014), 2008–2013 döneminde spot altın getiri ve oynaklığında uzun hafıza bulmuş, vadeli piyasada bulmamıştır. Küresel kriz sonrası bir yapısal kırılma tespit edilmiştir; bu, tek bir dönem ortalamasının yanıltıcı olabileceğini gösterir.

Makine öğrenmesi çalışmalarında değişken önemi. Aşağıdaki sıralamalar her çalışmanın kendi modeline aittir ve nedensellik göstermez.

Çalışma	Hedef	Öne çıkan değişkenler
Abar (2020)	Ons altın (USD)	ABD TÜFE, gümüş, ABD federal fon faizi
Öndes ve Oğuzlar (2019)	Ons altın (USD)	Gümüş (0,881), EUR/USD (0,774), petrol (0,746)
Akkuş (2025)	Ons altın log getirisi	Gümüş, ABD 10 yıllık tahvil faizi, S&P 500
Sürücü ve Türkan (2026)	Ons altın (USD), aylık	Gümüş, BIST 100, NASDAQ
Duman vd. (2025)	Ons altın (USD)	WTI, VIX, S&P 500, DXY
Akbar (2026)	Antam fiziksel altın (IDR)	Kapanış fiyatı, EMA 21, EMA 9
Ikasatya vd. (2026)	Günlük altın fiyatı	Yakın geçmiş fiyat aralıkları, hareketli ortalamalar

USD/TRY kuru literatürde neredeyse hiç kullanılmamıştır; yalnızca Kocatepe ve Yıldız (2016) ve Çınarar (2025) TL tarafını modele katmıştır. Oysa gram altının TL fiyatı tanımı gereği ons altın ve USD/TRY'nin çarpımına dayanır; bu ilişki Bölüm 9'da modelin temeli olarak kullanılmaktadır.

3. Tekil Model Karşılaştırmaları

Literatürde her koşulda kazanan tek bir model yoktur. Ağaç tabanlı topluluk modelleri (Random Forest, Gradient Boosting, XGBoost) en sık birinci olan ailedir; ancak sıralama veri dönemine, hedef değişkene ve doğrulama tasarımına göre değişmektedir.

Çalışma	Veri	Karşılaştırılan modeller	En iyi model ve sonucu	Bölme yöntemi
Manjula ve Karthikeyan (2019)	Aylık, 2000–2018, ons (INR)	LR, RF, GBR	Tüm dönem RF (R^2 0,980); yatay 2. dönemde GBR (R^2 0,629; LR 0,155)	%80/20, kronoloji belirsiz
Makala ve Li (2021)	Günlük, 1979–2019, ons (USD)	ARIMA, SVM (doğrusal, polinom, RBF)	SVM polinom (R^2 0,9978); ARIMA R^2 0,8615	Kronolojik (test 2015–2019)
Abar (2020)	Günlük, 2015–2020, ons (USD)	XGBoost, MARS, LR	XGBoost (RMSE 89,70; MAPE 0,512; R^2 0,996)	Rastgele %80/20
Öndes ve Oğuzlar (2019)	Günlük, 2005–2017, ons (USD)	YSA (5–25 nöron)	25 nöron (R^2 0,8265; MAPE %5,43)	Rastgele %70/15/15
Sürücü ve Türkan (2026)	Aylık, 2004–2024, ons (USD)	LR, MARS, RF, XGBoost, YSA, Voting	MARS en düşük MSE (54,13) ve en yüksek R^2 (0,9867); YSA en düşük MAPE (%3,27); Voting 58,59; XGBoost 60,29; RF 64,64; LR 81,16 (MSE)	Kronolojik (test 2020–2024)

Çalışma	Veri	Karşılaştırılan modeller	En iyi model ve sonucu	Bölme yöntemi
Akkuş (2025)	Günlük, 2006–2025, ons log getirisi	RF, XGBoost, SVR, LSTM	RF (test R^2 0,627); LSTM 0,604; XGBoost 0,595; SVR negatif	%70–80 eğitim + 5 katlı CV
Duman vd. (2025)	Günlük, ons (USD)	RF, HistGB, KNN, MLP	RF (MAPE %3,50; R^2 0,96); MLP %29,10	%80/20, kronoloji belirsiz
Ikasatya vd. (2026)	Günlük, 2004–, 5.391 gözlem	RF, XGBoost, LSTM	LSTM (MAPE %2,27)	Özette belirtilmemiş

Das vd. (2022) derlemesi de bu tabloyu destekler: SVR ve SVM sık öne çıkar, KNN zayıf kalır. Ancak derlemedeki çalışmalar farklı hedef ve ölçütler kullandığından ortak bir sıralama çıkarılamaz.

Tablodan çıkan dört sonuç:

- **XGBoost ile RF arasında net kazanan yok.** RF; Akkuş (2025) ve Akbar (2026) çalışmalarında önde çıkmıştır. Sürücü ve Türkan (2026) çalışmasında ise XGBoost MSE ve R^2 'de RF'nin önünde, MAPE'de gerisindedir. İkisi birlikte denenmelidir.
- **LSTM her zaman üstün değildir.** Ikasatya vd. (2026) çalışmasında birinci, Akkuş (2025) çalışmasında RF'nin gerisindedir.
- **Çok yüksek R^2 değerleri (0,99 üstü) çoğunlukla rastgele bölme ve fiyat seviyesi hedefiyle elde edilmiştir.** Getiri hedefleyen Akkuş (2025) çalışmasında en iyi test R^2 yalnızca 0,627'dir; seviye hedefinde R^2 kolayca şişer.
- **Piyasa rejimi sonucu değiştirir.** Manjula ve Karthikeyan (2019) çalışmasında yatay dönemde tüm modellerin R^2 değeri sert düşmüştür.

Eğitim başarısı da yanıltıcı olabilir. Sürücü ve Türkan (2026) çalışmasında XGBoost'un MAPE değeri eğitimde %0,73 iken testte %3,79'a çıkmıştır; aynı çalışmada tek bir model bütün ölçütlerde birinci olmamıştır.

4. Fiziksel / Gram Altın ve Günlük Tahmin Çalışmaları

Projeye en yakın çalışmalar Endonezya'daki Antam fiziksel altını üzerinedir. Günlük T+1 tahmin ve walk-forward doğrulama ile yaklaşık %0,6–1,2 MAPE raporlanmıştır. Türkiye gram altını için ise yalnızca aylık yön tahmini ve eski bir günlük çalışma bulunmaktadır.

Çalışma	Piyasa ve veri	Girdiler	Model	Sonuç	Doğrulama
Kocatepe ve Yıldız (2016)	Türkiye gram altın; aylık 2007–2015, 105 gözlem	13 makro değişken (Dolar/TL dahil), bir ay gecikmeli	YSA (13-16-13)	Yön tahmini; test doğruluğu %76,19 (21 aydan 16'sı)	Kronolojik 84/21 ay
Hisyam vd. (2025)	Antam (IDR/gram); günlük 2010–2025, 4.210 gözlem	MA, EMA, RSI, MACD, günlük getiri	XGBoost + Bayesian optimizasyon	Ortalama MAPE %1,03 (satış), %1,15 (geri alım); son pencerede %2,42	Walk-forward, 59 pencere x 14 gün
Akbar (2026)	Antam; günlük 2020–2025, 2.048 gözlem	Gecikmeli fiyat, EMA, RSI, MACD, getiri	RF, XGBoost	RF MAPE %0,780; XGBoost %0,878	Walk-forward

Çalışma	Piyasa ve veri	Girdiler	Model	Sonuç	Doğrulama
Ashari vd. (2026)	Antam; günlük (dönem özetinde yok)	Gecikmeli fiyat, USD/IDR, Brent, hareketli istatistik, takvim	LSTM-XGBoost ağırlıklı topluluk	MAPE 0,0058 (yaklaşık %0,58); R ² 0,9971; naïve modelden iyi	Ağırlık doğrulama verisinde seçilmiş
Aladağ vd. (2012)	Türkiye günlük en yüksek altın fiyatı	Özette yok	Bulanık zaman serisi + tahmin birleştirme (VCM, MSFE, YSA)	Sayısal sonuç özetinde yok	Özette yok

Bu grup üç ders vermektedir:

- **Kur girdisi önemlidir.** Gelişmekte olan piyasada döviz kurunu kullanan tek günlük çalışma Ashari vd. (2026) olup USD/IDR girdisi almıştır. Türkiye'deki karşılığı USD/TRY'dir.
- **Hata zamanla değişir.** Hisyam vd. (2025) çalışmasında ortalama MAPE %1,03 iken son pencerede %2,42'ye çıkmıştır. Tek bir ortalama hata yeterli değildir.
- **Yön doğruluğu dengesiz olabilir.** Kocatepe ve Yıldız (2016) modeli artışların %85,48'ini, azalışların yalnızca %60,47'sini doğru bilmiştir. Yükselen bir seride "hep artış" demek bile yüksek doğruluk verir; bu yüzden yön başarısı da basit bir referansla kıyaslanmalıdır.

5. Hibrit ve Tahmin Birleştirme Yaklaşımları

Hibrit modeller, raporlandıkları her çalışmada tekil referans modelden daha düşük hata vermiştir. En açık kazanç Shang ve Hamori (2023) çalışmasıdır: mevsimsel ayrıştırma-ARIMA-LSTM, RMSE'yi tek başına ARIMA'ya göre 9,27'den 2,88'e (yaklaşık %69) düşürmüştür.

Literatürdeki hibritler dört mantıkta toplanmaktadır:

Hibrit türü	Çalışma mantığı	Örnek çalışma	Raporlanan sonuç
Ayrıştırma + istatistiksel model + öğrenen model	Seri trend, mevsimsellik ve gürültü gibi bileşenlere ayrılır; her bileşen uygun modelle tahmin edilir	Shang ve Hamori (2023)	Ayrıştırma-ARIMA-LSTM RMSE 2,88; Wavelet-ARIMA-LSTM 3,13; Wavelet-ARIMA-XGBoost 3,56; Wavelet-ARIMA-RF 5,04; ARIMA 9,27 (walk-forward)
Ağırlıklı topluluk	Nihai tahmin = $w \times \text{LSTM} + (1 - w) \times \text{XGBoost}$; w doğrulama verisinde seçilir	Ashari vd. (2026)	MAPE yaklaşık %0,58; naïve modelden iyi
Artık (hata) düzeltme	Birinci model tahmin eder, ikinci model birincinin hatasını öğrenip ekler	Nainggolan vd. (2026): LSTM + XGBoost; ICITISEE (2025): VAR + LSTM	LSTM + XGBoost RMSE 0,0989, Diebold-Mariano ile LSTM ve ARIMA'ya üstün ($p < 0,01$); VAR + LSTM MAPE %4,79, DM istatistiği -12,66
Tahmin birleştirme	Birden fazla modelin tahmini istatistiksel ya da öğrenilmiş ağırlıklarla birleştirilir	Aladağ vd. (2012); Sürücü ve Türkan (2026) (Voting Regressor); Çınarler (2025) (GRU-RNN)	Çınarler: F1 %98,39 (sınıflandırma ölçütü, fiyat hatası değil); diğerlerinde sayısal sonuç özetinde veya notlarda yok

İki uyarı öne çıkmaktadır. Birincisi, Ashari, Nainggolan ve İkasatya çalışmalarının özetleri tekil modellerin sayısal hatalarını vermez; bu yüzden hibrit kazancın büyüklüğü bilinmemektedir. İkincisi, artık düzeltme yaklaşımı hem en açıklanabilir hibrittir hem de Bölüm 9'daki yapısal modelin doğal uzantısıdır.

6. Değerlendirme Metodolojisi

Literatürdeki en yaygın zayıflık model değil, değerlendirme tasarımıdır. Birçok çalışma rastgele ya da belirsiz bölme kullanmış, çok azı basit naïve modelle karşılaştırma yapmıştır. Bu durum raporlanan başarıları olduğundan iyi gösterebilir.

Bergmeir vd. (2018), klasik K-fold çapraz doğrulamanın yalnızca belirli koşullarda (otoregresif model, ilişkisiz hatalar) geçerli olduğunu göstermiştir. Bu koşullar finansal fiyat serilerinde garanti olmadığından kronolojik ve walk-forward doğrulama güvenli varsayılandır.

Dael (2026), örtüşen gözlemler ve rastgele değerlendirmenin finansal tahminde gerçekçi olmayan sonuçlar ürettiğini vurgular. Walk-forward ve örtüşmeyen gözlemlerle tüm modeller persistence modelini geçmiş; ortalama doğruluk yaklaşık %69, RF için AUC 0,786 olmuştur.

Uygulama	Neden gerekli	Uygulayan çalışmalar
Walk-forward doğrulama	Model farklı dönemlerde, yalnızca geçmişi görerek test edilir	Hisyam vd. (2025); Akbar (2026); Shang ve Hamori (2023); Nainggolan vd. (2026); Dael (2026)
Tek seferlik kronolojik bölme	Gelecek bilgisinin eğitime sızmasını önler	Makala ve Li (2021); Kocatepe ve Yıldız (2016); Sürücü ve Türkan (2026)
Naïve (persistence) referans	Modelin "bugünkü fiyatı tekrar etmekten" fazlasını yapıp yapmadığını gösterir	Ashari vd. (2026); Dael (2026)
Diebold–Mariano testi	İki modelin hata farkının istatistiksel olarak anlamlı olup olmadığını sınar	Nainggolan vd. (2026); ICITISEE (2025)
Dönemsel performans	Model başarısı piyasa rejimine göre değişir	Manjula ve Karthikeyan (2019); Hisyam vd. (2025); Türkiye uzun hafıza çalışması (2014)
Rastgele ya da belirsiz bölme (kaçınılmalı)	Zaman sırası bozulur, sonuç iyimser çıkar	Rastgele: Abar (2020), Öndes ve Oğuzlar (2019). Belirsiz: Manjula ve Karthikeyan (2019), Duman vd. (2025), Akkuş (2025)

Veri sızıntısı yalnızca bölme ile sınırlı değildir. Ölçekleme parametreleri, eksik değer doldurma, teknik göstergeler ve hiperparametre araması da yalnızca tahmin anında bilinen veriyle yapılmalıdır.

7. Karşılaştırmalı Özet Tablo

Tablo, 23 çalışmayı projeye yakınlığına göre sıralar. "Yüksek" yakınlık; fiziksel ya da Türkiye altınını, günlük veya TL tarafını ele alan çalışmaları gösterir.

Çalışma	Hedef	Veri	Yöntem	Ana bulgu	Doğrulama	Projeye yakınlık
Ashari vd. (2026)	Antam fiziksel altın, T+1	Günlük	LSTM-XGBoost ağırlıklı topluluk	MAPE yaklaşık %0,58; naïve modelden iyi	Ağırlık doğrulama verisinde seçilmiş	Yüksek
Akbar (2026)	Antam fiziksel altın, T+1	Günlük, 2020-2025	RF, XGBoost	RF MAPE %0,780; XGBoost %0,878	Walk-forward	Yüksek
Hisyam vd. (2025)	Antam satış ve geri alım fiyatı	Günlük, 2010-2025	XGBoost + Bayesian optimizasyon	MAPE %1,03 (satış), %1,15 (geri alım)	Walk-forward, 59 pencere	Yüksek
Kocatepe ve Yıldız (2016)	Türkiye gram altın değişim yönü	Aylık, 2007-2015	YSA	Test doğruluğu %76,19	Kronolojik %80/20	Yüksek
Çınarer (2025)	TL külçe altın, USD/TRY, EUR/TRY	Aylık, 2000-2024	LSTM, GRU, BiLSTM, RNN ve hibritleri	GRU-RNN F1 %98,39	Özette belirtilmemiş	Yüksek
Aladağ vd. (2012)	Türkiye günlük en yüksek altın fiyatı	Günlük	Bulanık zaman serisi + tahmin birleştirme	Sayısal sonuç özette yok	Özette belirtilmemiş	Yüksek
Nainggolan vd. (2026)	Ons altın	Aylık, 2010-2025	LSTM + XGBoost artık düzeltme	RMSE 0,0989; LSTM ve ARIMA'ya üstün (DM, $p < 0,01$)	Walk-forward	Orta
Ikasatya vd. (2026)	Altın fiyatı	Günlük, 2004 sonrası	RF, XGBoost, LSTM	LSTM MAPE %2,27	Özette belirtilmemiş	Orta
Dael (2026)	Ons altın yönü	Günlük	Lojistik regresyon, RF, SVM, persistence	Doğruluk yaklaşık %69; RF AUC 0,786	Walk-forward, örtüşmeyen gözlem	Orta
Sürücü ve Türkan (2026)	Ons altın	Aylık, 2004-2024	LR, MARS, RF, XGBoost, YSA, Voting	MARS en düşük MSE (54,13); YSA en düşük MAPE (%3,27)	Kronolojik (test 2020-2024)	Orta
Akkuş (2025)	Ons altın log getirisi	Günlük, 2006-2025	RF, XGBoost, SVR, LSTM	RF test R^2 0,627	%70-80 eğitim + 5 katlı CV	Orta
ICITISEE (2025)	Altın fiyatı	Aylık, yaklaşık 25 yıl	SARIMAX, VAR, GARCH, LSTM, BiLSTM, GRU, VAR-LSTM	VAR-LSTM MAPE %4,79	Özette belirtilmemiş	Orta
Duman vd. (2025)	Ons altın	Günlük	RF, HistGB, KNN, MLP	RF MAPE %3,50	%80/20, kronoloji belirsiz	Orta
Shang ve Hamori (2023)	Altın vadeli işlem fiyatı	Günlük, 2004-2019	ARIMA, LSTM, XGBoost, RF ve hibritleri	Ayrıştırma-ARIMA-LSTM RMSE 2,88 (ARIMA 9,27)	Walk-forward	Orta

Çalışma	Hedef	Veri	Yöntem	Ana bulgu	Doğrulama	Projeye yakınlık
Makala ve Li (2021)	Ons altın	Günlük, 1979–2019	ARIMA, SVM	SVM polinom R^2 0,9978	Kronolojik (test 2015–2019)	Orta
Abar (2020)	Ons altın	Günlük, 2015–2020	XGBoost, MARS, LR	XGBoost R^2 0,996	Rastgele %80/20	Orta
Bergmeir vd. (2018)	Metodoloji (güneş lekesi serisi)	Yıllık, 1700–1988	K-fold ve örneklem dışı değerlendirme	K-fold yalnızca belirli koşullarda geçerli	Tahmin çalışması değil	Orta
Yurdakul ve Sefa (2015)	İstanbul Altın Borsası ons fiyatı (USD)	Aylık, 1996–2012	Engle–Granger, EGARCH	Uluslararası fiyat güçlü belirleyici	Tahmin çalışması değil	Orta
Türkiye uzun hafıza çalışması (2014)	Türkiye spot ve vadeli altın	2008–2013	ARFIMA–FIGARCH	Spot altında uzun hafıza; yapısal kırılma	Tahmin çalışması değil	Orta
Das vd. (2022)	Derleme	Son on yılın çalışmaları	SVM, SVR, LR, RF, KNN, XGBoost, LSTM, hibritler	SVR öne çıkar; KNN zayıf	Derleme	Düşük
Manjula ve Karthikeyan (2019)	Ons altın (INR)	Aylık, 2000–2018	LR, RF, GBR	Tüm dönem RF; alt dönemlerde GBR	%80/20, kronoloji belirsiz	Düşük
Öndes ve Oğuzlar (2019)	Ons altın (USD)	Günlük, 2005–2017	YSA	25 nöron MAPE %5,43	Rastgele %70/15/15	Düşük
Toraman vd. (2011)	Londra ons altın getirisi	Aylık, 1992–2010	MGARCH–CCC	Dolar endeksi ile –0,476 korelasyon	Tahmin çalışması değil	Düşük

Metrikler farklı hedef, ölçek ve para birimlerinde hesaplandığından satırlar arası sayısal kıyas yapılmamalıdır.

8. Sentez: Ortak Bulgular, Farklılaşan Sonuçlar ve Boşluk

Literatür üç noktada uzlaşmakta, iki noktada farklılaşmakta ve Türkiye gram altını için belirgin bir boşluk bırakmaktadır.

Uzlaşılan noktalar

1. Uluslararası altın fiyatı ve dolar göstergeleri en güçlü belirleyicilerdir (Yurdakul ve Sefa, 2015; Toraman vd., 2011).
2. Doğrusal olmayan modeller doğrusal regresyondan iyidir. Abar (2020), Manjula ve Karthikeyan (2019) ile Sürücü ve Türkan (2026) çalışmalarında doğrusal regresyon son sıradadır.
3. Hibrit modeller, raporlandıkları her çalışmada tekil referansın önüne geçmiştir.

Farklılaşan noktalar

1. RF, XGBoost ve LSTM sıralaması çalışmadan çalışmaya değişir; kalıcı bir kazanan yoktur.
2. Makro değişkenlerin katkısı çalışmaya göre değişir. Toraman vd. (2011) enflasyonu anlamsız bulurken Abar (2020) ABD TÜFE'yi en önemli değişken bulmuştur.


Literatürdeki boşluk

Boşluk	Literatürdeki durum	Projenin yanıtı
TL/gram altın, günlük T+1 hedefi	Hiçbir çalışma bu hedefi doğrudan ele almıyor	Hedef değişken doğrudan gram altın TL fiyatı
USD/TRY girdisi	Yalnızca iki çalışmada var, ikisi de aylık	Ons altın ve USD/TRY ana girdiler
Naïve referansla kıyas	Yalnızca iki çalışmada var	Tüm modeller naïve modellerle kıyaslanır
Hibrit kazancın ölçülmesi	Tekil model sonuçları çoğu özette yok	Aynı walk-forward pencerelerinde tekil ve hibrit kıyası, Diebold-Mariano testi
Türkiye'ye özgü piyasa rejimleri	Tek çalışma, 2008-2013 ile sınırlı	Sakin ve kur şoku dönemlerinde ayrı performans raporu
Tahmin belirsizliği	Hiçbir çalışma tahmin aralığı sunmuyor	Nokta tahminin yanında güven aralığı

Gözden kaçan teknik bir sorun. Ağaç tabanlı modeller (RF, XGBoost) eğitimde görmedikleri değerlerin dışına tahmin üretmez. Gram altın TL fiyatı yüksek enflasyon nedeniyle sürekli yeni zirveler yaptığından, fiyat seviyesiyle eğitilen bir ağaç modeli test döneminde yatay bir çizgiye takılır. Rastgele bölme bu sorunu gizler; bu da bazı çalışmalardaki 0,99 üstü R^2 değerlerini kısmen açıklar.

9. Projeye Önerilen Yöntem

Önerilen yaklaşım, gram altının yapısal tanımından başlayan üç katmanlı bir hibrittir: parite tabanlı temel, makine öğrenmesiyle düzeltme ve modellerin birleştirilmesi. Literatürdeki en güçlü üç fikri (artık düzeltme, ağırlıklı topluluk, walk-forward) Türkiye'ye özgü kur bilgisiyle birleştirir ve konuyu aşırı karmaşıktırılmaz.

Hibrit katman ancak referansları aynı testte geçerse tutulur

Şekil 1. Önerilen tahmin hattı

Referanslar, tekil modeller ve hibrit katman aynı walk-forward pencerelerinde değerlendirilir. Hibrit katman, ancak naïve modeli ve en iyi tekil modeli anlamlı biçimde geçerse son sistemde tutulur.

9.1. Yapısal temel: parite fiyatı

Gram altının TL fiyatı yaklaşık olarak aşağıdaki kimlikle ifade edilir. Burada 31,1035 bir troy onsun gram karşılığı, m ise iç piyasa primidir.

$$P_{gram,t} \approx \frac{P_{ons,t} \times K_{USD/TRY,t}}{31,1035} \times (1 + m_t)$$

Bu kimlik fiyat seviyesinin büyük kısmını açıklar. Asıl tahmin edilmesi gereken, ons ve kurun yarınki değişimi ile primdir. Bu çerçevenin üç faydası vardır:

- **Dışdeğerleme sorunu çözülür.** Modeller fiyat seviyesi yerine log getiri ve prim tahmin eder; fiyat sonradan geri hesaplanır. Böylece RF ve XGBoost, eğitimde görülmeyen fiyat seviyelerinde de çalışır.
- **Tahmin açıklanabilir olur.** Tahmin edilen değişimin ne kadarının ons, kur ve primden geldiği ayrıştırılabilir ve web arayüzünde gösterilebilir.
- **Literatür boşluğu doğrudan kapanır.** USD/TRY, modelin kenar değişkeni değil, yapısal bileşenidir.

9.2. Hedef değişken ve özellikler

Hedef, ertesi günün log getirisidir: $y = \ln(P(t+1) / P(t))$. Tahmin edilen fiyat $P(t) \times \exp(\hat{y})$ ile geri hesaplanır.

Özellik grubu	Örnekler	Literatür dayanağı
Geçmiş gram altın	1, 2, 5 ve 10 gün gecikmeli getiriler	Akbar (2026); Iksatya vd. (2026)

Özellik grubu	Örnekler	Literatür dayanağı
Ons altın	Günlük getiri ve gecikmeleri	Yurdakul ve Sefa (2015); Toraman vd. (2011)
USD/TRY	Günlük getiri, gecikmeler, 20 günlük oynaklık	Kocatepe ve Yıldız (2016); Ashari vd. (2026) (USD/IDR)
İç piyasa primi	m ve hareketli ortalaması	Projenin özgün katkısı
Teknik göstergeler	EMA 9 ve 21, RSI, MACD	Hisyam vd. (2025); Akbar (2026)
Küresel risk (isteğe bağlı)	Gümüş, DXY, VIX, ABD 10 yıllık faiz	Akkuş (2025); Duman vd. (2025)
Takvim	Haftanın günü	Ashari vd. (2026)

Tüm özellikler yalnızca t günü kapanışında bilinen verilerden hesaplanmalıdır. Gram altın kapanış saati ile ons ve kur verisinin saati aynı ana hizalanmalıdır; aksi hâlde model tahmin değil, hesaplama yapmış olur.

9.3. Model hiyerarşisi

Modeller basitten karmaşığa eklenir; her katman bir öncekini geçtiği ölçüde tutulur.

1. **Naïve referans:** Yarının fiyatı bugünün fiyatıdır.
2. **İstatistiksel referans:** ARIMA (Makala ve Li, 2021; Shang ve Hamori, 2023).
3. **Tekil modeller:** RF, XGBoost ve LSTM; üçü de log getiri hedefli ve aynı özelliklerle.
4. **Hibrit A, artık düzeltme:** LSTM tahmin eder, XGBoost LSTM'nin hatasını öğrenip ekler (Nainggolan vd., 2026; ICITISEE, 2025).
5. **Hibrit B, ağırlıklı topluluk:** RF, XGBoost ve LSTM tahminleri doğrulama döneminde belirlenen ağırlıklarla birleştirilir (Ashari vd., 2026; Aladağ vd., 2012).

Hiperparametreler Bayesian optimizasyonla (örneğin Optuna) yalnızca doğrulama pencerelerinde aranır (Hisyam vd., 2025). Wavelet ve mevsimsel ayrıştırma gibi daha ağır hibritler ileri çalışma olarak bırakılabilir.

9.4. Değerlendirme planı

- **Veri dönemi:** 2018, 2021 ve 2023 kur şoklarını kapsayan en az 8–10 yıllık günlük veri.
- **Doğrulama:** Genişleyen pencereleli walk-forward; model belirli aralıklarla yeniden eğitilir.
- **Ölçütler:** TL cinsinden MAE ve RMSE, MAPE, yön doğruluğu ve naïve modele göre beceri skoru ($1 - \text{MAE model} / \text{MAE naïve}$).
- **İstatistiksel test:** Her model naïve modele ve en iyi tekil modele karşı Diebold–Mariano testiyle sınanır.
- **Rejim analizi:** Sakin ve kur şoku dönemleri için ayrı sonuç tablosu.
- **Ablasyon:** Ons ve kur, prim ve teknik göstergeler tek tek çıkarılarak katkıları ölçülür.
- **Belirsizlik:** Nokta tahminin yanında, örneğin conformal tahminle %90 güven aralığı üretilir ve arayüzde bant olarak gösterilir.

Günlük altın fiyatında naïve modeli geçmek zordur. Bu nedenle küçük ama Diebold–Mariano testiyle anlamlı bir iyileşme, literatürdeki 0,99 R² iddialarından daha değerli bir sonuçtur.

9.5. Sistem mimarisi

Veriler (TCMB EVDS ve piyasa kaynakları) Microsoft SQL Server'da saklanır. Python eğitim hattı (Pandas, NumPy, scikit-learn, XGBoost, LSTM) her gün yeni tahmin üretir ve sonuçları REST API ile web arayüzüne sunar. Arayüz; ertesi gün tahmini, güven bandı, ons–kur–prim katkı ayrıştırması ve model karşılaştırma tablosunu gösterir.

Kaynakça

Kaynaklar APA 7 biçimindedir.

- Abar, H. (2020). XGBoost ve MARS yöntemleriyle altın fiyatlarının kestirimi. *EKEV Akademi Dergisi*, (83), 427–446. <https://dergipark.org.tr/tr/download/article-file/2578712>
- Akbar, N. F. (2026). Perbandingan algoritma XGBoost dan Random Forest dalam peramalan harga emas Antam menggunakan indikator teknikal. *Prosiding Seminar Nasional Indonesia*, 4(1). <https://doi.org/10.5281/zenodo.20742370>
- Akkuş, H. T. (2025). Altın fiyatlarının tahmininde makine öğrenmesi ve derin öğrenme yaklaşımları. *Pamukkale Üniversitesi Sosyal Bilimler Enstitüsü Dergisi*, (71, EYS'25 Özel Sayısı), 129–142. <https://doi.org/10.30794/pausbed.1776824>
- Aladağ, Ç. H., Eğrioğlu, E., & Kadılar, C. (2012). Forecasting gold prices series in Turkey by the forecast combination. In *Advances in Time Series Forecasting* (pp. 108–117). Bentham Science Publishers. <https://doi.org/10.2174/978160805373511201010108>
- Ashari, A., Situmorang, Z., & Rosnelly, R. (2026). Long short term memory and gradient boosting model for one day ahead forecasting of ANTAM gold bar prices. *Jurnal Teknik Informatika (JUTIF)*, 7(2), 1704–1713. <https://doi.org/10.52436/1.jutif.2026.7.2.5630>
- Bergmeir, C., Hyndman, R. J., & Koo, B. (2018). A note on the validity of cross-validation for evaluating autoregressive time series prediction. *Computational Statistics & Data Analysis*, 120, 70–83. <https://doi.org/10.1016/j.csda.2017.11.003>
- Comparative analysis of time series and deep learning models for forecasting gold price under macroeconomic conditions. (2025). In *2025 9th International Conference on Information Technology, Information Systems and Electrical Engineering (ICITISEE)*. IEEE. <https://doi.org/10.1109/ICITISEE68184.2025.11355108>
- Çınarar, G. (2025). Forecasting current exchange and gold rates with hybrid models using time series and deep learning algorithms. *International Journal of 3D Printing Technologies and Digital Industry*, 9(2). <https://dergipark.org.tr/tr/pub/ij3dptdi/article/1633193>
- Dael, F. (2026). Gold price direction prediction using machine learning with walk-forward validation. *Sakarya University Journal of Computer and Information Sciences*, 9(4), 1209–1219. <https://doi.org/10.35377/saucis.1834952>
- Das, S., Nayak, J., Rao, B. K., Vakula, K., & Routray, A. R. (2022). Gold price forecasting using machine learning techniques: Review of a decade. In A. K. Das et al. (Eds.), *Computational Intelligence in Pattern Recognition* (Advances in Intelligent Systems and Computing, Vol. 1349, pp. 679–695). Springer. https://doi.org/10.1007/978-981-16-2543-5_58
- Duman, S., Turnacıgil, S., Arık, E., & Aktaş, M. A. (2025). The role of international variables in predicting gold prices: Analysis with machine learning algorithms. *Sosyoekonomi*, 33(63), 103–113. <https://doi.org/10.17233/sosyoekonomi.2025.01.05>
- Hisyam, M., Fitri, Z., & Aidilof, H. A. K. (2025). Implementasi algoritma XGBoost dengan walk forward validation untuk prediksi harga emas Antam. *JURIKOM (Jurnal Riset Komputer)*, 12(4), 403–413. <https://doi.org/10.30865/jurikom.v12i4.8693>

- Ikasatya, R. A., Apriliani, C., & Firdaus, F. J. (2026). A hybrid machine learning and long short-term memory approach for gold price prediction to support strategic decision-making in the bullion business. *Dynamics in Engineering Systems: Innovations and Applications*, 3(1), 1–19. <https://doi.org/10.61511/dynames.v3i1.3458>
- Kocatepe, C. İ., & Yıldız, O. (2016). Ekonomik endeksler kullanılarak Türkiye'deki altın fiyatındaki değişim yönünün yapay sinir ağları ile tahmini. *Düzce Üniversitesi Bilim ve Teknoloji Dergisi*, 4(3), 926–934. <https://dergipark.org.tr/tr/download/article-file/224881>
- Long memory and structural breaks in the returns and volatility of gold: Evidence from Turkey. (2014). *Applied Economics*. <https://doi.org/10.1080/00036846.2014.929627>
- Makala, D., & Li, Z. (2021). Prediction of gold price with ARIMA and SVM. *Journal of Physics: Conference Series*, 1767(1), 012022. <https://doi.org/10.1088/1742-6596/1767/1/012022>
- Manjula, K. A., & Karthikeyan, P. (2019). Gold price prediction using ensemble based machine learning techniques. In *2019 3rd International Conference on Trends in Electronics and Informatics (ICOEI)* (pp. 1360–1364). IEEE. <https://doi.org/10.1109/ICOEI.2019.8862557>
- Nainggolan, A. J. B., Hutajulu, Y. A., Kevin, K., & Nababan, M. N. K. (2026). Hybrid LSTM–XGBoost model with residual error correction for multivariate gold price forecasting using macroeconomic indicators. *Research in Education, Technology, and Multiculture*, 5(1), 60–74. <https://doi.org/10.61436/rietm/v5i1.pp60-74>
- Öndes, H., & Oğuzlar, A. (2019). Yapay sinir ağlarıyla altın (TL/KG) fiyatı tahmini. *Akademik Bakış Uluslararası Hakemli Sosyal Bilimler E-Dergisi*, (72), 249–262. <https://dergipark.org.tr/tr/download/article-file/775849>
- Shang, J., & Hamori, S. (2023). Do large datasets or hybrid integrated models outperform simple ones in predicting commodity prices and foreign exchange rates? *Journal of Risk and Financial Management*, 16(6), 298. <https://doi.org/10.3390/jrfm16060298>
- Sürücü, A. Y., & Türkan, S. (2026). Machine learning-based comparative analysis of the determinants of gold prices. *Erciyes University Journal of the Institute of Science and Technology*, 42(1), 277–293. <https://doi.org/10.65520/erciyesfen.1777185>
- Toraman, C., Başarır, Ç., & Bayramoğlu, M. F. (2011). Altın fiyatlarını etkileyen faktörlerin tespiti üzerine: MGARCH modeli ile bir inceleme. *Uluslararası Alanya İşletme Fakültesi Dergisi*, 3(1), 1–20. <https://dergipark.org.tr/tr/pub/uaifd/article/231830>
- Yurdakul, F., & Sefa, M. (2015). An econometric analysis of gold prices in Turkey. *Procedia Economics and Finance*, 23, 77–85. [https://doi.org/10.1016/S2212-5671\(15\)00332-9](https://doi.org/10.1016/S2212-5671(15)00332-9)